

UNIVERSIDAD LATINA DE COSTA RICA

Inteligencia en Redes de Datos
BIT-31

SEMANA 14 DESARROLLO Y ANÁLISIS DE RESULTADOS

*Plataforma inteligente para clasificación y atención de incidentes de red
Qwen2.5:3b + Ollama + RAG + FastMCP + PostgreSQL*

Autores:

Alejandro Moran Reyes (202401114359)
Kendall Valerin Solano (202401100994)

Profesor:

Ing. Carlos Andrés Méndez Rodríguez

San José, agosto de 2026

1. Introducción


Durante la Semana 14 se realizó la fase de desarrollo experimental y análisis de resultados de la plataforma inteligente para clasificación y atención de incidentes de red. Esta etapa corresponde a la ejecución práctica de la metodología planteada previamente, en la cual se estableció una estrategia incremental para validar cada componente antes de integrarlo.

El prototipo integra un modelo de lenguaje local Qwen2.5:3b ejecutado mediante Ollama, una base documental RAG construida con Sentence Transformers y ChromaDB, un servidor FastMCP para consultar información operativa y PostgreSQL como repositorio de dispositivos, métricas y tickets. La experimentación se enfocó en comprobar el funcionamiento conjunto de estos componentes y medir precisión, latencia, CPU y memoria.

2. Implementación de experimentos y simulaciones

2.1 Modelo local con Ollama

Se instaló Ollama y se descargó el modelo Qwen2.5:3b. Posteriormente se verificó su disponibilidad mediante la lista de modelos locales y se realizó una prueba desde Python. El modelo respondió correctamente a un incidente de red, confirmando que la inferencia local estaba operativa antes de continuar con la integración.



```
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ ollama list
NAME          ID          SIZE    MODIFIED
qwen2.5:3b    357c53fb659c 1.9 GB  25 hours ago
```

Figura 1. Modelo Qwen2.5:3b instalado y disponible en Ollama.

2.2 Base de datos PostgreSQL

Se creó la base de datos incidentes_red y se implementaron las tablas dispositivos, metricas y tickets. Se cargaron dispositivos y valores de prueba para simular información de una infraestructura de red. Entre los datos utilizados se incluyó SW-CORE-01 con CPU de 92,3 %, memoria de 81,5 % y latencia de 145,7 ms.

```
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ psql -h 127.0.0.1 -U
app_incidentes -d incidentes_red
Password for user app_incidentes:
psql (18.4 (Ubuntu 18.4-0ubuntu0.26.04.1))
SSL connection (protocol: TLSv1.3, cipher: TLS_AES_256_GCM_SHA384, compr
ession: off, ALPN: postgresql)
Type "help" for help.

incidentes_red=> \dt
          List of tables
 Schema |      Name      | Type  | Owner
-----+-----+-----+-----
 public | dispositivos   | table | postgres
 public | metricas       | table | postgres
 public | tickets        | table | postgres
(3 rows)

incidentes_red=> SELECT hostname, tipo, ubicacion, estado FROM dispositi
vos;
 hostname |      tipo      |      ubicacion      | estado
-----+-----+-----+-----
 RTR-CORE-01 | Router        | Centro de Datos    | Activo
 SW-CORE-01  | Switch        | Centro de Datos    | Activo
 SW-ACCESS-01 | Switch        | Edificio A         | Activo
 AP-WIFI-01  | Access Point  | Edificio B         | Activo
 SRV-DNS-01  | Servidor DNS  | Centro de Datos    | Activo
(5 rows)

incidentes_red=>
```

Figura 2. Base de datos PostgreSQL con dispositivos, métricas y tickets.

2.3 Servidor FastMCP

El servidor MCP se implementó mediante FastMCP. Se desarrollaron cuatro herramientas: `listar_dispositivos`, `consultar_dispositivo`, `consultar_metricas` y `buscar_tickets`. Las pruebas confirmaron que el servidor podía consultar PostgreSQL y devolver información operativa al resto de la plataforma.

```
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ fastmcp list src/servidor_mcp.py
[08/13/26 22:48:41] INFO      Starting MCP server      transport.py:241
                             'Servidor de Incidentes de
                             Red' with transport
                             'stdio'

Tools (4)

listar_dispositivos() -> dict
    Lista los dispositivos registrados en el inventario.

consultar_dispositivo(hostname: str) -> dict
    Consulta información de un dispositivo por hostname.

consultar_metricas(hostname: str) -> dict
    Consulta las métricas más recientes de un dispositivo.

buscar_tiquetes(texto: str) -> dict
    Busca tiquetes que contengan un texto determinado.

(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ |
```

Figura 3. Herramientas disponibles en el servidor FastMCP.

2.4 Implementación del RAG

La base documental se construyó con cuatro procedimientos técnicos: conectividad, DNS, autenticación y rendimiento. Los documentos fueron convertidos a embeddings mediante Sentence Transformers y almacenados en ChromaDB. La creación del índice confirmó cuatro documentos disponibles para recuperación semántica.

```
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ python src/crear_rag.py
Cargando modelo de embeddings...
Warning: You are sending unauthenticated requests to the HF Hub. Please
set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|██████████| 103/103 [00:00<00:00, 480.55it/s]
Documentos encontrados: 4

=== RAG CREADO CORRECTAMENTE ===
- conectividad
- autenticacion
- rendimiento
- dns

Total de documentos indexados: 4
```

Figura 4. Creación e indexación de los documentos del RAG.

2.5 Integración final

La aplicación final integró la descripción del incidente, las métricas consultadas mediante MCP y el procedimiento recuperado por RAG. Esta información se incorporó en un prompt estructurado enviado a Qwen2.5:3b. La salida solicitada incluyó categoría, prioridad, diagnóstico, evidencia y acción recomendada.

```
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$ python src/plataforma
.py
Cargando modelo de embeddings...
Warning: You are sending unauthenticated requests to the HF Hub. Please
set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100%|██████████| 103/103 [00:00<00:00, 526.19it/s]

=== INCIDENTE RECIBIDO ===

SW-CORE-01 presenta lentitud.
Los usuarios reportan problemas de rendimiento.

=== INFORMACION RAG ===
Archivo recuperado: autenticacion.txt

PROCEDIMIENTO: PROBLEMAS DE AUTENTICACIÓN

1. Confirmar que el usuario tenga conectividad de red.
2. Verificar que las credenciales sean correctas.
3. Revisar la disponibilidad del servidor de autenticación.
4. Comprobar si la cuenta se encuentra bloqueada.
5. Verificar la sincronización de hora entre cliente y servidor.
6. Revisar los registros de autenticación.
7. Si el servicio central no responde, escalar el incidente.
```

FASTMCP

FastMCP 3.4.7
<https://gofastmcp.com>

 **Server:** Servidor de Incidentes de Red, 3.4.7
 **Deploy free:** <https://horizon.prefect.io>

```
[08/13/26 22:52:00] INFO Starting MCP server transport.py:241
'Servidor de Incidentes de
Red' with transport
'stdio'
```

```

=== INFORMACION MCP ===
CallToolResult(content=[TextContent(type='text', text='{"hostname":"SW-CORE-01","cpu":92.3,"memoria":81.5,"latencia_ms":145.7,"fecha":"2026-08-12 22:05:20.906589"}', annotations=None, meta=None)], structured_content={'hostname': 'SW-CORE-01', 'cpu': 92.3, 'memoria': 81.5, 'latencia_ms': 145.7, 'fecha': '2026-08-12 22:05:20.906589'}, meta=None, data={'hostname': 'SW-CORE-01', 'cpu': 92.3, 'memoria': 81.5, 'latencia_ms': 145.7, 'fecha': '2026-08-12 22:05:20.906589'}, is_error=False)

=== RESPUESTA FINAL QWEN2.5:3B ===

Categoria: Rendimiento
Prioridad: Media
Diagnostico: SW-CORE-01 presenta lentitud y los usuarios reportan problemas de rendimiento, lo que sugiere un problema en el rendimiento del sistema.
Evidencia:
- CallToolResult con latencia_ms de 145.7 ms (considerablemente alta según las reglas)
- Procedimiento recuperado mediante RAG menciona PROBLEMAS DE AUTENTICACIÓN
Acción recomendada:
Corroborar la validez y actualización del sistema operativo e inquilinos en SW-CORE-01. Ejecutar el script de mantenimiento en caliente si es necesario para verificar que los componentes estén correctamente configurados y funcionando. Si persiste, realizar un análisis detallado de SW-CORE-01 buscando posibles causas subyacentes como conflictos de software o problemas de hardware. En última instancia, reiniciar el servicio en caliente si no se encuentran soluciones.
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$

```

Figura 5. Respuesta final del sistema integrando Qwen2.5:3b, RAG y MCP.

3. Diseño de la evaluación

Para medir el desempeño se implementó un script de evaluación con ocho casos de prueba. Se utilizaron dos incidentes para cada una de las categorías Rendimiento, Conectividad, DNS y Autenticación. Para cada ejecución se registró la categoría esperada, categoría predicha, documento recuperado mediante RAG, latencia, utilización de CPU y memoria.

Caso	Incidente	Categoría esperada
1	Switch principal con lentitud y alta latencia.	Rendimiento
2	Usuario sin acceso a Internet y gateway sin respuesta.	Conectividad

3	Usuarios no pueden resolver nombres de dominio.	DNS
4	Usuario no puede iniciar sesión con sus credenciales.	Autenticación
5	Red muy lenta y pérdida de rendimiento.	Rendimiento
6	Interfaz del router caída y sin conectividad.	Conectividad
7	Servidor DNS no responde a las consultas.	DNS
8	Cuenta del usuario bloqueada.	Autenticación

4. Resultados preliminares

En la primera ejecución de la evaluación se obtuvo una precisión de 87,50 %. Siete de los ocho casos fueron marcados como correctos. El caso restante correspondió a Autenticación: la etiqueta esperada estaba escrita como “Autenticacion”, mientras que Qwen2.5:3b respondió “Autenticación”. Aunque ambas expresiones representan la misma categoría, la comparación literal de cadenas las consideró diferentes.

Este resultado preliminar fue importante porque permitió detectar una limitación en el método de evaluación y no necesariamente un error del modelo. También durante el desarrollo se observó que un prompt demasiado abierto podía provocar una clasificación incoherente, por lo que fue necesario definir reglas más claras para cada categoría.

```

Caso 1
Incidente: El switch principal presenta lentitud y alta latencia
.
Real: Rendimiento
Predicha: Rendimiento
RAG: rendimiento.txt
Latencia: 28.0 s
Correcto: True
-----
Caso 2
Incidente: El usuario no puede acceder a Internet y el gateway n
o responde.
Real: Conectividad
Predicha: Conectividad
RAG: conectividad.txt
Latencia: 12.64 s
Correcto: True
-----
Caso 3
Incidente: Los usuarios no pueden resolver nombres de dominio.
Real: DNS
Predicha: DNS
RAG: dns.txt
Latencia: 11.85 s
Correcto: True
-----

```



```

-----
Caso 4
Incidente: El usuario no puede iniciar sesion con sus credencial
es.
Real: Autenticacion
Predicha: Autenticación
RAG: autenticacion.txt
Latencia: 12.39 s
Correcto: False
-----
Caso 5
Incidente: La red esta muy lenta y hay perdida de rendimiento.
Real: Rendimiento
Predicha: Rendimiento
RAG: rendimiento.txt
Latencia: 12.21 s
Correcto: True
-----
Caso 6
Incidente: La interfaz del router esta caída y no hay conectivid
ad.
Real: Conectividad
Predicha: Conectividad
RAG: conectividad.txt
Latencia: 12.75 s
Correcto: True
-----
Caso 7
Incidente: El servidor DNS no responde a las consultas.
Real: DNS
Predicha: DNS
RAG: dns.txt
Latencia: 11.71 s
Correcto: True
-----
Caso 8
Incidente: La cuenta del usuario aparece bloqueada.
Real: Autenticacion
Predicha: Autenticacion
RAG: rendimiento.txt
Latencia: 12.14 s
Correcto: True
-----

=== RESULTADOS GENERALES ===
Casos evaluados: 8
Precision: 87.50%
Latencia promedio: 14.21 segundos

Resultados guardados en: /home/kvale/proyecto_incidentes_red/res
ultados/evaluacion.csv
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$

```

Figura 6. Primera evaluación con precisión de 87,50 %.

5. Análisis y ajustes realizados

A partir de los resultados preliminares se realizaron ajustes metodológicos y técnicos. Primero, el evaluador fue modificado para normalizar las etiquetas antes de compararlas, eliminando diferencias de mayúsculas, espacios y tildes. De esta forma, “Autenticacion” y “Autenticación” se reconocen como equivalentes.

En segundo lugar, se reforzó el prompt utilizado por el modelo. Se definieron explícitamente las cuatro categorías válidas y se agregaron criterios asociados a cada una: latencia, CPU y memoria para Rendimiento; pérdida de conexión y gateway para Conectividad; resolución de nombres para DNS; y credenciales o cuentas bloqueadas para Autenticación. También se indicó al modelo que no inventara información no presente en los datos proporcionados.

Estos cambios evidencian la adaptabilidad de la metodología: la implementación no se trató como un proceso rígido, sino como un ciclo de prueba, análisis, identificación de problemas, ajuste y nueva evaluación.

6. Resultados finales

Métrica	Resultado
Casos evaluados	8
Clasificaciones correctas	8 de 8
Precisión	100,00 %
Latencia promedio	14,62 segundos
CPU promedio al finalizar	44,52 %
Memoria promedio del proceso	961,62 MB

Después de aplicar los ajustes se repitieron los ocho experimentos. Todas las categorías fueron reconocidas correctamente, obteniéndose una precisión final de 100,00 %. La latencia promedio fue de 14,62 segundos por incidente. El script registró 44,52 % de CPU promedio al finalizar las pruebas y 961,62 MB de memoria promedio para el proceso evaluado.

```
=== INICIO DE EVALUACION ===
```

```
Caso 1
```

```
Incidente: El switch principal presenta lentitud y alta latencia
```

```
Real: Rendimiento
```

```
Predicha: Rendimiento
```

```
RAG: rendimiento.txt
```

```
Latencia: 30.96 s
```

```
Correcto: True
```

```
-----
```

```
Caso 2
```

```
Incidente: El usuario no puede acceder a Internet y el gateway n  
o responde.
```

```
Real: Conectividad
```

```
Predicha: Conectividad
```

```
RAG: conectividad.txt
```

```
Latencia: 12.62 s
```

```
Correcto: True
```

```
-----
```

```
Caso 3
```

```
Incidente: Los usuarios no pueden resolver nombres de dominio.
```

```
Real: DNS
```

```
Predicha: DNS
```

```
RAG: dns.txt
```

```
Latencia: 11.54 s
```

```
Correcto: True
```

```
-----
```

```
|
```

```
-----
```

```
Caso 4
```

```
Incidente: El usuario no puede iniciar sesion con sus credencial  
es.
```

```
Real: Autenticacion
```

```
Predicha: Autenticacion
```

```
RAG: autenticacion.txt
```

```
Latencia: 12.45 s
```

```
Correcto: True
```

```
-----
```

```
Caso 5
```

```
Incidente: La red esta muy lenta y hay perdida de rendimiento.
```

```
Real: Rendimiento
```

```
Predicha: Rendimiento
```

```
RAG: rendimiento.txt
```

```
Latencia: 12.59 s
```

```
Correcto: True
```

```
-----
```

```
Caso 6
```

```
Incidente: La interfaz del router esta calda y no hay conectivid  
ad.
```

```
Real: Conectividad
```

```
Predicha: Conectividad
```

```
RAG: conectividad.txt
```

```
Latencia: 12.7 s
```

```
Correcto: True
```

```
-----
```

```
|
```

```

-----
Caso 7
Incidente: El servidor DNS no responde a las consultas.
Real: DNS
Predicha: DNS
RAG: dns.txt
Latencia: 12.27 s
Correcto: True
-----

Caso 8
Incidente: La cuenta del usuario aparece bloqueada.
Real: Autenticacion
Predicha: Autenticación
RAG: rendimiento.txt
Latencia: 11.84 s
Correcto: True
-----

=== RESULTADOS GENERALES ===
Casos evaluados: 8
Precisión: 100.00%
Latencia promedio: 14.62 segundos
CPU promedio al finalizar: 44.52%
Memoria promedio del proceso: 961.62 MB

Resultados guardados en: /home/kvale/proyecto_incidentes_red/res
ultados/evaluacion.csv
(.venv) kvale@HPSolider:~/proyecto_incidentes_red$

```

Figura 7. Resultados generales de la evaluación final: 100 % de precisión.

7. Discusión de los resultados

La precisión obtenida demuestra que el prototipo logró distinguir correctamente los incidentes incluidos en el conjunto de evaluación. No obstante, el tamaño de la muestra es reducido, por lo que el 100 % no debe interpretarse como garantía de igual desempeño ante cualquier incidente real. Para una evaluación más robusta sería necesario ampliar considerablemente el número y la diversidad de casos.

La latencia promedio de 14,62 segundos representa una de las principales limitaciones observadas. El modelo fue ejecutado localmente mediante CPU, por lo que el tiempo de inferencia es mayor que el esperado en una infraestructura con aceleración por GPU. Aun así, el resultado permite demostrar la viabilidad funcional del prototipo sin depender de una API externa.

El componente RAG mostró un comportamiento adecuado en la mayoría de las pruebas, pero se detectó una limitación relevante en el caso 8. El incidente relacionado con una cuenta bloqueada fue clasificado correctamente como Autenticación, aunque el RAG recuperó rendimiento.txt. Esto demuestra que la clasificación final puede ser correcta aun cuando la recuperación documental no sea óptima, y señala la necesidad de mejorar la estrategia de recuperación.

La utilización de MCP permitió incorporar métricas e información estructurada procedente de PostgreSQL. Esto reduce la dependencia exclusiva del conocimiento interno del modelo y permite fundamentar el diagnóstico en datos definidos para la infraestructura simulada.

8. Adaptabilidad de la metodología

Los experimentos realizados durante la Semana 14 permitieron aplicar de manera directa el enfoque incremental definido en el proyecto. Cada componente se validó individualmente y los problemas encontrados durante la integración dieron lugar a ajustes antes de ejecutar nuevamente la evaluación.

La primera precisión de 87,50 % llevó a revisar el mecanismo de comparación y detectar que la diferencia era ortográfica y no conceptual. De forma similar, las respuestas iniciales del modelo motivaron la incorporación de reglas explícitas al prompt. Finalmente, la recuperación incorrecta de un documento RAG fue conservada como una limitación del prototipo y como punto de mejora, en lugar de modificar los datos para ocultar el resultado.

Por lo tanto, la metodología mostró capacidad de adaptación a la evidencia obtenida durante las pruebas, manteniendo trazabilidad entre los resultados preliminares, los cambios aplicados y los resultados finales.

9. Conclusiones de la Semana 14

La fase experimental permitió comprobar el funcionamiento conjunto de Qwen2.5:3b, Ollama, RAG, FastMCP y PostgreSQL. Los ocho casos finales fueron clasificados correctamente, alcanzando una precisión de 100 %, con una latencia promedio de 14,62 segundos.

Los resultados también permitieron identificar limitaciones concretas. La inferencia local por CPU presenta una latencia considerable y la recuperación RAG todavía puede seleccionar un procedimiento incorrecto. Estas observaciones son importantes porque muestran que la evaluación no se limitó a reportar resultados positivos, sino que permitió detectar aspectos que requieren optimización.

Finalmente, los ajustes realizados entre la evaluación preliminar y la final evidencian la adaptabilidad del diseño metodológico. La normalización de etiquetas y el refinamiento del prompt mejoraron la consistencia de la evaluación y de la clasificación, cumpliendo con las actividades planteadas para la Semana 14.

10. Evidencias Adjuntadas

- Captura de Ollama mostrando qwen2.5:3b instalado.
- Captura de las tablas y datos de PostgreSQL.
- Captura de las cuatro herramientas de FastMCP.
- Captura de la creación del RAG con cuatro documentos.
- Captura de una consulta integrada RAG + MCP + Qwen.
- Captura de la evaluación preliminar con 87,50 %.
- Captura de los resultados finales con 100 %, 14,62 s, 44,52 % CPU y 961,62 MB.